

S2H-CD-FSOD 周报

周期: 2026-09-28 ~ 10-07

论文	Trust What You Transfer: Knowledge-Enhanced Hard-Soft Reasoning for Cross-Domain Few-Shot Object Detection (CVPR 2026 投稿)
方法	S2H-CD-FSOD = FFCP + CHSD + ATAR, 建立在 Domain-RAG 复现的 Grounding DINO (Swin-B) 配方之上
代码仓库	/mnt/sdc/hzh/Domain-RAG-main-2/mmdetection

一、实验目标与方案

1.1 本阶段目标

本阶段目标是验证 Hard-Soft 方法是否能够在 Grounding DINO 基础上稳定提升 few-shot detection 的 mAP, 并确认:

- baseline $\rightarrow$ FFCP $\rightarrow$ FFCP+CHSD $\rightarrow$ full 是否能够逐阶段提升;
- ATAR 的不确定性门控是否有效;
- Hard/Soft 原型方向、可靠性和修正强度是否真正参与推理;
- 在不改变 bbox 回归分支的情况下, 分类校准能否改善最终检测排序。

1.2 数据集与消融协议

- 主要验证集: dataset = clipart1k, shot = 5-shot, seed = 3407, test images = 500
- 消融阶段: baseline $\rightarrow$ ffcf $\rightarrow$ ffcf_chsd $\rightarrow$ full
- 控制变量: 同一 checkpoint、同一 test images、seed = 3407, $\gamma \in \{0, 1, 4, 8\}$, soft_mix = 0.35, $\theta = 0.5$, $T_u = 0.1$

二、实验进展

2.1 配置与代码同步

当前 S2H 配置已统一为:

```
correction_mode      = 'contrastive'
routing_confidence    = 'sigmoid'
reliability_power     = 1.0
train_injection       = False
res_weight            = 0.0
con_weight            = 0.0
soft_mix              = 0.35
```

同时修复了一个重要问题: 此前 soft_mix 只存在于配置中, 而实际 atar() 中始终使用 Soft prototype, 导致 Hard-Soft 混合没有真正生效。修复后:

```
ffcp:
    direction = soft

ffcp_chsd / full:
    direction = normalize(
        (1 - soft_mix) * hard + soft_mix * soft
    )
```

已通过 Python 编译与运行时检查。

2.2 诊断工具运行结果

50 张图像的诊断结果如下：

stage	mean delta	r_bar	active
ffcp	0.0170	0.8287	1.0000
ffcp_chsd	0.0154	0.4522	1.0000
full	0.0139	0.4514	0.9991

Hard/Soft agreement 平均约为 0.5454，mean reliability 约为 0.8289。这表明 Hard 与 Soft 原型的方向一致性较低，CHSD 阶段可靠性明显下降。

2.3 门控尺度问题已定位

原始配置中 $\theta = 0.5$ 、 $T_u = 0.1$ ，但当前 Grounding DINO 的分类 logits 经过 sigmoid 后非常小： $p_0 \text{ median} \approx 0.0068$ ， $p_0 95\% \approx 0.0272$ 。

$$u = \text{sigmoid}((0.5 - p_0) / 0.1) \approx 0.99$$

因此 full 阶段的 ATAR 门控几乎一直处于开启状态。将参数调整为 $\theta = 0.01$ 、 $T_u = 0.01$ 后，门控数值上变得更有区分度： $u \approx 0.525$ ，active ratio ≈ 0.726 ，但 mAP 从 0.593 降回 0.591。

结论：门控校准不是当前的主要性能瓶颈，最终配置暂时仍保留默认门控。

2.4 gamma 参数已确认生效

gamma	mean delta	max delta
0	0.0000	0.0000
1	0.0132	0.0563
4	0.0528	0.2251
8	0.1056	0.4503

修正量严格按照 gamma 成比例变化，说明：配置覆盖有效；knowledge bank 已正确加载；ATAR 实际参与推理；问题不在参数未生效。

2.5 同一 checkpoint 的 gamma 实验

gamma	mAP	mAP50	mAP75	mAP_s	mAP_m	mAP_l
0	0.591	0.811	0.690	0.354	0.551	0.664
1	0.591	0.811	0.690	0.354	0.551	0.664
4	0.592	0.812	0.690	0.354	0.551	0.664
6	0.592	0.813	0.690	0.357	0.552	0.664
7	0.593	0.813	0.691	0.356	0.551	0.665
8	0.593	0.813	0.691	0.356	0.551	0.664
9	0.593	0.813	0.691	0.357	0.551	0.663
10	0.593	0.813	0.691	0.357	0.551	0.663
12	0.593	0.812	0.691	0.362	0.551	0.662

当前推理后校准的最高提升约为 0.591 → 0.593，说明当前 Hard-Soft 方向具有弱正作用，但收益已经出现平台期。

2.6 soft_mix 实验

固定 gamma = 8 后：

soft_mix	mAP	mAP50	mAP75
0.00	0.593	0.813	0.691
0.25	0.593	0.813	0.691
0.35	0.593	0.813	0.691
0.50	0.593	0.812	0.690
0.75	0.592	0.812	0.690
1.00	0.592	0.812	0.690

当前最稳定的方向组合是 soft_mix = 0.25 ~ 0.35。建议继续使用 soft_mix = 0.35，因为它符合原始 Hard-Soft 方法设定，且没有证据证明 0.25 显著优于 0.35。

三、当前存在的主要问题

3.1 问题一：知识特征与修正对象不在同一表示空间

当前 Soft prototype 的构建流程为：

```
support image
|-> model.extract_feat()
|-> backbone/neck feature pyramid
|-> GT box pooling
|-> Soft prototype
```

而运行时修正对象为：

```
decoder query hidden state
|-> Grounding DINO ContrastiveEmbed
|-> classification logits
|-> S2H correction
```

也就是说，当前 Soft prototype 来自 backbone/neck 框内池化特征，而 ATAR 中的查询特征来自 decoder hidden state。虽然二者都是 256 维，但这不代表它们属于同一个几何表示空间。当前方法实际上是在用 backbone/neck 空间中的方向修正 decoder query 空间中的分类结果，这很可能是性能受限的根本原因。

3.2 问题二：CHSD 阶段 Hard/Soft agreement 过低

当前 Hard/Soft agreement 约为 0.54，意味着 Hard identity anchor 和 Soft appearance prototype 的夹角接近正交，CHSD 中使用二者混合方向后，可能引入错误的类别偏移。

阶段	baseline	ffcp	ffcp_chsd	full
mAP	0.592	0.592	0.587	0.591

这也解释了当前结果：损失主要发生在 CHSD，full 只能部分恢复。

3.3 问题三：训练阶段没有看到 S2H 修正

当前配置 train_injection = False、res_weight = 0.0、con_weight = 0.0，因此模型训练过程实际上仍是普通 Grounding DINO，S2H 只在测试时对分类 logits 做后处理。这会导致：

- decoder query 没有学习适应 Soft prototype；
- 分类分数分布没有针对修正进行重新校准；
- gamma 放大后主要改变候选排序，而不是提升真实目标置信度；
- mAP 提升被限制在约 0.002。

3.4 问题四：目前是全局修正，不是类别自适应修正

当前 gamma 是全局标量，g_cls 也是全局标量。不同类别的 AP 出现相反变化：部分类别提升，部分类别下降，全局 mAP 只小幅变化。这说明不同类别需要不同的 correction strength，单一 gamma 无法同时适配所有类别。

四、下一步计划

下一阶段的核心任务确定为：在 decoder-query 表示空间中重新构建 Soft prototype，验证表示空间对齐是否是当前性能瓶颈。

不建议立即继续搜索 gamma，也不建议立刻扩展到六个数据集。应先在 clipart1k 5-shot seed 3407 上完成结构性验证。

4.1 阶段 A：建立 decoder-query 特征审计

目标：确认 decoder-query Soft prototype 是否比当前 backbone/neck Soft prototype 更接近真实检测查询的分类空间。

方法：对每张 support 图像——

- 使用 baseline Grounding DINO，不启用 S2H；
- 获取最后一个 decoder layer 的 query hidden states；
- 获取 query 预测框；
- 将 query 框与 support GT 框进行 IoU 匹配；
- 对匹配到类别 c 的 query hidden state 做归一化；
- 汇总得到新的 decoder-space prototype。

定义：

$$q_{i,c} = \text{Norm}(H_{i,j^*})$$

其中 H_{i,j^*} 是匹配到 GT 类别 c 的 decoder query; j^* 是与 GT 框 IoU 最大且超过阈值的 query。新的 Soft prototype 为：

$$s_c^Q = \text{Norm}((1 - \beta_c) \cdot \text{RobustMean}(q_{i,c}) + \beta_c h_c)$$

其中 h_c 是文本 Hard prototype, β_c 是小样本收缩系数, RobustMean 用于降低错误 query 的影响。第一轮只验证原始 query-space Soft prototype, 不同时加入 FFCP 与复杂 CHSD, 避免多个因素混在一起。

4.2 阶段 B: 新增 query-space knowledge builder

计划新增 tools/s2h/build_s2h_query_knowledge.py, 输出格式仍保持兼容：

```
{
  "hard":      [C, D],
  "soft":      [C, D],
  "kappa":     [C],
  "reliability": [C],
  "classes":   [...],
  "token_ids": [...],
  "meta": {
    "stage": "query_soft",
    "representation": "decoder_query",
    "source": "support_only",
    "checkpoint": "...",
    "iou_threshold": 0.5
  }
}
```

必须增加以下校验：

- knowledge 只能使用 support/training 图像；
- 不允许读取 test 标注；
- 类别顺序必须和配置一致；
- query hidden dimension 必须等于 embed_dims；
- knowledge 文件中记录 representation 类型；
- 如果是旧的 neck-space knowledge, 运行时给出明确警告。

4.3 阶段 C: 同一 checkpoint 的结构对照实验

使用同一个 full checkpoint, 只替换 knowledge 文件: control 为当前 neck-space Soft prototype, experiment 为 decoder-query-space Soft prototype。控制变量保持完全一致: checkpoint 相同、test images 相同、 $\gamma \in \{1, 4, 8\}$ 、soft_mix = 0.35、theta = 0.5、 $T_u = 0.1$ 、seed = 3407。

knowledge	gamma	目的
neck-space	0	关闭修正
neck-space	8	当前方法基线
query-space	1	检查方向是否稳定
query-space	4	中等修正
query-space	8	检查是否超过当前方法

如果 query-space 在同一 checkpoint 上达到 mAP > 0.593，并且不是只依赖某一个类别，则说明表示空间错配确实是主要问题。更理想的判据是：query-space 至少提升 0.003 ~ 0.005 mAP，同时不能只靠小目标 AP 增益而牺牲大目标 AP。

4.4 阶段 D：在 query-space 中重新加入 FFCP

如果阶段 C 有效，再将 FFCP 从 neck-space 迁移到 query-space。对于原始图像、同域干预图像、类别错配图像和重建图像，分别提取匹配 query：

$$d_{r,c} = (q_c^{fg} - q_c^{\sim r}) - (q_c^{fg} - q_c^{rec})$$

然后在 query-space drift 上估计：

$$U_{ctx}^Q = \text{SVD}(d_{r,c})$$

并执行上下文清除：

$$q_c^{clean} = (I - U_{ctx}^Q U_{ctx}^{Q^T}) q_c^{fg}$$

这样 FFCP 的上下文清除和最终 ATAR 修正将处于同一个 decoder-query 几何空间中。

4.5 阶段 E：重新验证 CHSD

只有在 query-space FFCP 有正收益后，才重新加入 CHSD：Hard text anchor + query-space Soft appearance prototype。重点监控 Hard/Soft agreement、reliability、delta_mean_abs、per-class AP。

目标不是盲目让 agreement 越高，而是确认：

- Hard/Soft 不再出现大面积冲突；
- CHSD 不再从 FFCP 阶段明显掉点；
- full 至少不低于 FFCP；
- 最终形成合理的累计趋势。

4.6 阶段 F：最后再开启训练注入

query-space knowledge 验证有效后，再进行训练注入实验：

```
train_injection = True
res_weight      = 0.01
con_weight      = 0.01
gamma           = 1.0
soft_mix        = 0.35
```

训练初期不直接使用 gamma = 8，原因是 gamma = 8 是测试时找到的后处理强度，不能直接假设适合训练分布。训练注入的顺序为：

- baseline checkpoint;
- full + query-space knowledge;
- $\gamma = 1$ 训练;
- 测试时搜索 $\gamma = 1, 2, 4$;
- 再决定是否扩大训练强度。

五、下一阶段的验收标准

下一阶段不以“单次测试得到更高数字”为唯一标准，而采用以下条件。

5.1 结构正确性

- query-space knowledge 只使用 support 数据;
- query prototype 与 decoder hidden state 维度和表示空间一致;
- 旧 neck-space knowledge 与新 query-space knowledge 可以明确区分;
- 同一 checkpoint 下替换 knowledge 后修正量确实发生变化。

5.2 性能有效性

- query-space 同 checkpoint mAP 至少超过当前 0.593;
- 不只提升单一类别;
- mAP50、mAP75 不出现明显反向下降;
- 小目标提升不能以大目标显著下降为代价。

5.3 消融合理性

目标趋势为 $\text{baseline} \leq \text{ffcp} \leq \text{ffcp_chsd} \leq \text{full}$ ，但在单个 seed 下不强行要求严格单调。最终需要至少 3 seeds、6 datasets、1/5/10 shots 进行统计验证后，才能作为论文中的正式结果。

5.4 当前阶段最终配置

参数	取值	说明
γ	8.0	测试时后处理强度
soft_mix	0.35	Hard/Soft 方向混合比例
θ	0.5	门控阈值
T_u	0.1	门控温度
train_injection	False	暂不开启训练注入

该配置只作为旧方法的对照配置，不应被视为最终 SOTA 方案。下一阶段的核心判断将是：decoder-query 空间重建的 Soft prototype 能否把目前 0.591 ~ 0.593 的后处理收益转化为稳定、可训练、可跨数据集复现的性能提升。